

TUGAS 3

APACHE AIRFLOW UNTUK MEMPROSES BATCH DARI PENGAMBILAN DATA SAMPAI SIAP DITAMPILKAN DI DASHBOARD

MATA KULIAH BIG DATA PLATFORM

Dosen Pengampu:

Dr. Yudi Wibisono, M.T.



Disusun oleh:

Kelompok 1

Faisal Nur Qolbi	2311399
Hafidz Tantowi	2308817
Muhammad Farhan	2309323
Muhammad Helmi Rahmadi	2311574
Sifa Imania Nurul Hidayah	2312084
Yazid Madarizel	2305328

PROGRAM STUDI ILMU KOMPUTER

FAKULTAS PENDIDIKAN MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS PENDIDIKAN INDONESIA

2025

1. Pendahuluan

Dalam era digital saat ini, kebutuhan akan data yang bersih, konsisten, dan tersedia secara real-time maupun batch menjadi sangat penting untuk pengambilan keputusan yang tepat. Salah satu tantangan besar dalam pengelolaan data adalah bagaimana mengotomatisasi proses pengambilan, transformasi, dan penyimpanan data dari berbagai sumber agar siap digunakan dalam sistem analitik atau dashboard.

Proyek ini bertujuan untuk membangun pipeline ETL (Extract, Transform, Load) berbasis batch menggunakan Apache Airflow, sebuah orkestrator alur kerja yang memungkinkan penjadwalan dan pemantauan alur data secara terstruktur dan modular.

Sumber data yang digunakan terdiri dari:

- YFinance: menyediakan data harga saham historis secara tabular,
- IQPlus: sumber berita harian terkait emiten dan pasar modal Indonesia,
- IDX: menyajikan laporan keuangan perusahaan publik dalam format XML

Dengan mengintegrasikan ketiga sumber ini dalam sistem yang terautomasi, diharapkan pengguna dapat memperoleh informasi terkini dan komprehensif mengenai kondisi keuangan dan performa saham emiten tertentu. Hasil akhir dari pipeline ini akan disimpan dalam MongoDB dan dapat digunakan lebih lanjut oleh sistem backend atau dashboard analitik untuk visualisasi data.

2. Arsitektur Alur Data

Diagram Alur Data ETL:

[Sumber Data] —> [Extract] —> [Transform] —> [Load ke MongoDB] —> [API] —> [Dashboard]

2.1 Sumber Data:

- YFinance (<https://finance.yahoo.com/>) – Harga saham historis
- IQPlus (<http://www.iqplus.info/>) – Berita harian emiten
- IDX (<https://www.idx.co.id/id/perusahaan-tercatat/laporan-keuangan-dan-tahunan/>) – Laporan keuangan dalam format XML

2.2 ETL Pipeline:

Setiap sumber data diproses melalui pipeline ETL (Extract, Transform, Load) yang dijalankan dan dikelola oleh Apache Airflow. Proses ini memastikan data dari sumber berbeda dapat digunakan secara konsisten dan efisien untuk keperluan analisis lebih lanjut.

2.2.1 Extract

Proses extract dilakukan untuk mengambil data mentah dari masing-masing sumber dengan pendekatan yang berbeda tergantung pada format dan aksesibilitas sumber data:

- YFinance: Pengambilan data dilakukan menggunakan library Yfinance yang menyediakan antarmuka untuk mengunduh data harga saham historis berdasarkan kode saham (ticker).
- IQPlus : Pengambilan data dilakukan menggunakan scraping dari web sumber data berita yaitu IQPlus dengan menggunakan Selenium dan WebDriver untuk mencari dan mengambil informasi terbaru secara otomatis. Proses ini melibatkan penelusuran halaman web, pencarian elemen berdasarkan tag atau class tertentu, serta ekstraksi judul berita, tanggal, dan isi konten untuk disimpan ke dalam format yang dapat diolah lebih lanjut.
- IDX (Bursa Efek Indonesia): Pengambilan data dilakukan menggunakan scraping dari web sumber data IDX dengan menggunakan selenium dan webdriver untuk mencari instance.zip pada setiap emiten di laporan keuangan, kami mengambil khusus data laporan tahunan/audit saja. Pada instance.zip terdapat Taxonomy.xsd dan instance.xrbl yang dimana langsung di convert menjadi JSON dan disimpan ke mongodb

2.2.2 Transform:

- YFinance : Melakukan pembersihan dan konversi data agar seragam. Pada data saham, dilakukan konversi ke berbagai agregasi waktu seperti mingguan dan bulanan
- IQPlus : Melakukan ringkasan pada konten yang sudah diambil melalui proses scraping, dengan memanfaatkan transformasi teks menggunakan model *transformer-based* untuk menghasilkan ringkasan otomatis yang padat.

- IDX (Bursa Efek Indonesia): Proses transformasi data dari laporan keuangan emiten IDX yang bersumber dari file instance.zip, yang telah di-scraping dan disimpan di MongoDB database IDXData dalam koleksi Financial_2021, Financial_2022, Financial_2023, dan Financial_2024, diawali dengan pengaturan koneksi utama menggunakan Apache Spark dan cadangan menggunakan PyMongo ke MongoDB lokal di mongoddb://localhost:27017. Setelah data dari koleksi sumber dibaca, sistem mengidentifikasi daftar emiten dan memproses data per emiten. Tahap transformasi mencakup pengambilan data keuangan penting, pengubahan tipe data, serta perhitungan metrik tambahan seperti rasio keuangan (current ratio, asset to equity ratio, debt to equity ratio) dan margin (gross margin, operating margin, net margin); proses ini mereduksi jumlah atribut dari sekitar 300-500 menjadi 32 atribut kunci, ditambah penanganan nilai null menjadi nol dan pencatatan error dalam log. Data yang telah diolah kemudian disimpan dalam database mongoddb.

2.2.3 Load:

Tahap *load* adalah proses menyimpan hasil transformasi ke dalam sistem basis data, yaitu MongoDB. Data dari setiap sumber disimpan dalam koleksi (*collection*) yang berbeda untuk memudahkan pengelolaan, query, dan pemisahan logis antar jenis data. Penyimpanan dilakukan dalam format dokumen JSON agar tetap fleksibel dan mudah digunakan oleh API serta frontend dashboard.

2.3 Orkestrator

Apache Airflow digunakan sebagai orkestrator untuk mengatur urutan dan penjadwalan proses ETL. Airflow dijalankan dalam container Docker untuk kemudahan instalasi dan manajemen dependensi. Dengan Airflow, setiap langkah dalam pipeline dibuat sebagai task dalam DAG (Directed Acyclic Graph) yang dapat dikontrol waktu eksekusinya dan dapat dipantau melalui antarmuka web. Ini memungkinkan proses berjalan otomatis, terjadwal, dan dapat diulang jika terjadi kegagalan.

2.4 Penyimpanan Akhir

MongoDB dipilih sebagai sistem penyimpanan karena fleksibel dalam menangani berbagai bentuk data. Setiap jenis data disimpan dalam koleksi terpisah, misalnya koleksi untuk harga saham harian, mingguan, bulanan, berita emiten, dan laporan keuangan.

Penyimpanan dilakukan dalam bentuk dokumen JSON sehingga mudah untuk query dan integrasi dengan API.

2.5 Konsumsi Data

Setelah data masuk ke MongoDB, dibangun API backend menggunakan framework seperti Flask atau FastAPI untuk menyediakan data ke aplikasi dashboard atau pengguna akhir. API ini memungkinkan pengguna mengambil data berdasarkan parameter seperti nama saham, periode waktu, atau kata kunci berita. API menyajikan data dalam format JSON yang siap dikonsumsi oleh frontend atau aplikasi visualisasi.

3. Setting Airflow

A. Mempersiapkan Struktur Proyek

Struktur folder yang jelas diperlukan untuk mengorganisasi semua komponen proyek:

- dags/: Menyimpan file DAG (Directed Acyclic Graph) yang mengatur workflow Airflow. Setiap DAG berisi task yang perlu dieksekusi.
- data/: Menyimpan data yang digunakan selama pemrosesan, seperti CSV yang berisi daftar perusahaan dan data mentah hasil ekstraksi.
- logs/: Tempat menyimpan log eksekusi Airflow untuk pemantauan dan debugging.
- plugins/: Menyimpan plugin tambahan untuk memperluas fungsionalitas Airflow.
- api/: Menyimpan aplikasi API Flask untuk menampilkan data di dashboard.

B. Menulis Dockerfile

- Dockerfile untuk Airflow

Buat Dockerfile untuk Airflow yang menginstal pustaka dan alat yang diperlukan untuk menjalankan webserver, scheduler, dan worker.

- Dockerfile untuk API Flask

API Flask akan digunakan untuk menampilkan data di dashboard. Dockerfile ini menginstal pustaka yang diperlukan untuk menjalankan API Flask.

C. Menyusun Docker Compose File

Docker Compose digunakan untuk mendefinisikan dan menjalankan multi-container Docker aplikasi. Berikut adalah contoh docker-compose.yaml yang mengonfigurasi Image-Image yang dibutuhkan seperti:

- PostgreSQL untuk metadata Airflow

- Redis sebagai broker untuk Celery
- Airflow untuk menjalankan orkestrasi task
- MongoDB untuk penyimpanan data saham
- API Flask untuk menampilkan data di dashboard

Lakukan build image menggunakan perintah berikut:

`docker-compose build`

D. Menyiapkan Airflow

- Konfigurasi Airflow agar menggunakan CeleryExecutor yang memungkinkan eksekusi tugas terdistribusi oleh worker.
- Atur koneksi ke PostgreSQL dan Redis untuk memastikan Airflow dapat menyimpan metadata dan mengelola task.

Lakukan inisialisasi database Airflow menggunakan perintah berikut:

`docker-compose run --rm airflow-init`

E. Menjalankan Layanan Docker

Jalankan semua layanan yang telah dikonfigurasi dengan perintah:

`docker-compose up -d`

Perintah ini akan mengunduh image yang diperlukan dan menjalankan container untuk setiap layanan. Setelah itu, pastikan semua layanan berjalan dengan benar.

Lakukan pengecekan container yang sedang berjalan dengan perintah:

`docker ps`

F. Pengujian dan Monitoring

- UI Airflow dapat diakses di `http://localhost:8080` untuk memantau status DAG, task, dan scheduler.
- API Flask dapat diakses di `http://localhost:5000` untuk memastikan data dapat ditampilkan dengan benar di dashboard.

4. Implementasi dan Dokumentasi Airflow per Sumber

4.1. YFinance

A. Menambahkan dan Mengelola DAG

DAG (Directed Acyclic Graph) di Airflow berfungsi untuk mendefinisikan urutan tugas-tugas yang akan dieksekusi secara terjadwal. Setiap task dalam DAG adalah

langkah yang spesifik dalam proses ETL (Extract, Transform, Load). Berikut adalah cara penerapan proses ETL untuk Yfinance dalam DAG yang diatur dalam Airflow

- Extract:

Tahap ini dimulai dengan membaca daftar perusahaan dari sebuah file CSV. Dari sana, sistem mengakses layanan penyedia data saham untuk mengunduh riwayat harga saham masing-masing perusahaan, dimulai dari tahun 2014 hingga saat ini, termasuk data terbaru selama satu minggu terakhir.

Data yang diambil mencakup berbagai informasi pasar harian. Setelah diunduh, data diformat agar konsisten, terutama pada bagian tanggal. Selanjutnya, data tersebut disimpan ke dalam basis data khusus untuk menyimpan data mentah. Untuk menjaga akurasi dan menghindari duplikasi, data lama pada basis data dibersihkan terlebih dahulu sebelum data baru disimpan. Proses ini juga menghasilkan daftar perusahaan yang berhasil diproses, sebagai referensi untuk tahap berikutnya.

- Transform:


Proses transformasi dimulai dengan membaca ulang data mentah dari basis data berdasarkan daftar perusahaan yang berhasil diekstraksi. Data harian tersebut kemudian diproses ulang, dan versi baru dari data harian disimpan ulang dengan penanda khusus yang membedakannya dari data mentah.

Setelah itu, data dikelompokkan berdasarkan periode waktu, seperti per bulan dan per tahun. Untuk setiap kelompok, dihitung nilai ringkasan statistik seperti rata-rata harga, volume total, nilai maksimum, nilai minimum, dan simpangan baku. Hasil pengelompokan ini diperkaya dengan informasi waktu dan jenis agregasi (harian, bulanan, tahunan), lalu siap disimpan sebagai data hasil olahan.


- Load:

Data yang telah melalui proses transformasi kemudian disimpan ke dalam basis data khusus yang ditujukan untuk data yang telah siap dianalisis. Proses penyimpanan dilakukan secara efisien dalam kelompok data (batch), dan disusun berdasarkan perusahaan agar mudah diakses untuk kebutuhan analisis atau visualisasi lanjutan.


B. Dokumentasi




Scrapping Yfinance melalui Airflow



Transform Yfinance melalui Airflow



Load Yfinance melalui Airflow



Scrapping Yfinance melalui Airflow

4.2. IQPlus

A. Menambahkan dan Mengelola DAG

- Extract:

Proses ekstraksi pada IQPlus diimplementasikan dengan metode web scraping menggunakan Selenium. Berikut adalah langkah-langkah utama dalam proses ekstraksi, Sistem ini pertama-tama terhubung ke basis data MongoDB untuk menyimpan artikel berita, kemudian menggunakan Selenium untuk secara otomatis mengakses situs IQPlus dan mengumpulkan berita pasar keuangan dari berbagai halaman. Selama proses ekstraksi, sistem melakukan pengecekan terhadap artikel yang sudah ada di database guna menghindari pengolahan ulang. Artikel mentah yang berhasil diambil akan disimpan dalam koleksi *Berita_Extract.News*, dengan data penting seperti judul, waktu publikasi, tautan, dan konten artikel. Selain itu, sistem juga mencatat ID artikel baru untuk diproses pada tahap berikutnya.

Fungsi ekstraksi dirancang untuk bekerja secara inkremental, hanya memproses artikel baru yang belum ada di database. Sistem menggunakan mekanisme logging yang komprehensif untuk memantau proses.

- Transform:


Komponen transformasi berfungsi untuk mengolah artikel mentah menjadi ringkasan yang lebih padat dan informatif. Proses ini dimulai dengan mengambil artikel yang berstatus "belum" dari basis data, kemudian menggunakan model NLP BART-large-CNN untuk menghasilkan ringkasan. Untuk menangani artikel dengan teks yang panjang, sistem menerapkan strategi pemecahan-penggabungan (split-merge), yaitu dengan membagi teks menjadi beberapa bagian, merangkum masing-masing bagian secara terpisah, lalu menggabungkannya kembali untuk memperoleh ringkasan akhir yang koheren. Selain itu, sistem juga menghitung statistik seperti jumlah kata dan rasio kompresi, mengubah status artikel menjadi "selesai" setelah diproses, serta mencatat waktu pemrosesan dan durasi transformasi.

- Load:

Komponen loading bertugas untuk memindahkan data yang telah diproses ke basis data yang akan diakses oleh aplikasi frontend. Proses ini mencakup pengambilan artikel yang telah diringkas dari tahap transformasi, lalu menyimpannya ke dalam koleksi *Berita_Final.RingkasanBerita*. Sistem akan memperbarui artikel yang sudah ada atau membuat entri baru sesuai kebutuhan, serta mencatat status proses loading untuk setiap artikel.


Untuk membuat data ringkasan berita dapat diakses, sebuah layanan API berbasis Flask diimplementasikan dengan berbagai fitur, seperti endpoint untuk mendapatkan daftar semua berita dengan paginasi, endpoint untuk memperoleh detail artikel berdasarkan ID, serta kemampuan pencarian teks pada judul, konten, dan ringkasan berita.

B. Dokumentasi




```
ec7ef10f5de
*** Found local files:
*** * /opt/airflow/logs/dag_id=etl_iqplus_to_mongo_optimized/run_id=manual_2025-05-11T15:45:49.618312+00:00/task_id=extract_news/attempt=1.log
[2025-05-11, 15:46:00 UTC] [local_task_job_runner.py:120] ▶ Pre task execution logs
[2025-05-11, 15:46:00 UTC] [iqplus_etl_dag.py:45] INFO - 🚀 Memulai ekstraksi berita dari IQplus
[2025-05-11, 15:46:00 UTC] [iqplus_etl_dag.py:32] INFO - Mencoba menghubungkan ke MongoDB...
[2025-05-11, 15:46:00 UTC] [iqplus_etl_dag.py:35] INFO - Berhasil terhubung ke MongoDB!
[2025-05-11, 15:46:00 UTC] [iqplus_etl_dag.py:58] INFO - 📄 Batas maksimum halaman: 1
[2025-05-11, 15:46:00 UTC] [iqplus_etl_dag.py:72] INFO - 🚗 Menggunakan Chrome binary: /usr/bin/chromium
[2025-05-11, 15:46:00 UTC] [iqplus_etl_dag.py:76] INFO - 🚗 Menggunakan ChromeDriver: /usr/local/bin/chromedriver
[2025-05-11, 15:46:08 UTC] [iqplus_etl_dag.py:189] INFO - 📄 Halaman terakhir yang akan diproses: 1
[2025-05-11, 15:46:08 UTC] [iqplus_etl_dag.py:197] INFO - 🌐 Scraping halaman: http://www.iqplus.info/news/market-news/go-to-page-8.html
[2025-05-11, 15:46:13 UTC] [iqplus_etl_dag.py:179] INFO - ✅ Artikel baru disimpan: EKOM: OJK CATAT 24 EMITEN BUYBACK SAHAM TANPA RUPS SENILAI Rp937,42 MILIAR
[2025-05-11, 15:46:14 UTC] [iqplus_etl_dag.py:179] INFO - ✅ Artikel baru disimpan: EKOM: KEMENPERIN PERCEPAT DEKARBONISASI INDUSTRI MENUJU TARGET NZE
[2025-05-11, 15:46:15 UTC] [iqplus_etl_dag.py:179] INFO - ✅ Artikel baru disimpan: EKOM: BIO FARMA DORONG KEMANDIRIAN NASIONAL DALAM PERANG MELAWAN TBC
[2025-05-11, 15:46:17 UTC] [iqplus_etl_dag.py:179] INFO - ✅ Artikel baru disimpan: INEN: BANK ASING JUAL OBLIGASI INDIA AKIBAT KONFLIK
[2025-05-11, 15:46:18 UTC] [iqplus_etl_dag.py:179] INFO - ✅ Artikel baru disimpan: EKOM: IHSG SESI II DITUTUP MENGUAT 5 POIN KE LEVEL 6.832
[2025-05-11, 15:46:19 UTC] [iqplus_etl_dag.py:179] INFO - ✅ Artikel baru disimpan: EKOM: BI PETAKAN DAN GALI INVESTASI POTENSIAL GENJOT EKONOMI DI BALI
[2025-05-11, 15:46:22 UTC] [iqplus_etl_dag.py:179] INFO - ✅ Artikel baru disimpan: EKOM: PERTAMINA SUKSES CETAK 40 PEMIMPIN PEREMPUN
[2025-05-11, 15:46:23 UTC] [iqplus_etl_dag.py:179] INFO - ✅ Artikel baru disimpan: EKOM: ANGGOTA DPR DUKUNG PENINGKATAN PRODUKSI MIGAS NASIONAL
[2025-05-11, 15:46:24 UTC] [iqplus_etl_dag.py:179] INFO - ✅ Artikel baru disimpan: EKOM: OJK: MODAL ASING KELUAR PASAR SAHAM RI RP50,72 TRILIUN HINGGA APRIL
[2025-05-11, 15:46:25 UTC] [iqplus_etl_dag.py:179] INFO - ✅ Artikel baru disimpan: EKOM: MIND ID BERSINERGI DENGAN PERGURUAN TINGGI GUNA DORONG HILIRISASI
[2025-05-11, 15:46:26 UTC] [iqplus_etl_dag.py:179] INFO - ✅ Artikel baru disimpan: INEN: INVESTOR TETAP OPTIMIS, IMBAL HASIL OBLIGASI AS BERGERAK
```

Scraping IQplus melalui Airflow



```
b8ba304b4569
*** Found local files:
*** * /opt/airflow/logs/dag_id=etl_iqplus_to_mongo_optimized/run_id=manual_2025-05-11T11:33:25.167474+00:00/task_id=transform_news_data/attempt=1.log
[2025-05-11, 11:33:56 UTC] [local_task_job_runner.py:120] ▶ Pre task execution logs
[2025-05-11, 11:33:56 UTC] [iqplus_etl_dag.py:627] INFO - 🚀 Memulai transformasi data berita
[2025-05-11, 11:33:56 UTC] [iqplus_etl_dag.py:630] INFO - 🛠 Menginisialisasi model transformers...
[2025-05-11, 11:33:59 UTC] [log.py:232] WARNING - Device set to use cpu
[2025-05-11, 11:33:59 UTC] [iqplus_etl_dag.py:440] INFO - Mencoba menghubungkan ke MongoDB...
[2025-05-11, 11:33:59 UTC] [iqplus_etl_dag.py:443] INFO - Berhasil terhubung ke MongoDB!
[2025-05-11, 11:33:59 UTC] [iqplus_etl_dag.py:457] INFO - 📄 Jumlah artikel yang perlu ditransformasi: 90
[2025-05-11, 11:33:59 UTC] [iqplus_etl_dag.py:735] INFO - 📄 Heringkas artikel 1/90: EKOM: OJK CATAT 24 EMITEN BUYBACK SAHAM TANPA RUPS
[2025-05-11, 11:33:59 UTC] [log.py:232] WARNING - Asking to truncate to max_length but no maximum length is provided and the model has no predefined maximum length. Default to no truncation.
[2025-05-11, 11:34:36 UTC] [iqplus_etl_dag.py:759] INFO - ✅ Transformasi selesai untuk artikel: EKOM: OJK CATAT 24 EMITEN BUYBACK SAHAM TANPA RUPS
[2025-05-11, 11:34:36 UTC] [iqplus_etl_dag.py:735] INFO - 📄 Heringkas artikel 2/90: EKOM: KEMENPERIN PERCEPAT DEKARBONISASI INDUSTRI M
[2025-05-11, 11:35:06 UTC] [iqplus_etl_dag.py:759] INFO - ✅ Transformasi selesai untuk artikel: EKOM: KEMENPERIN PERCEPAT DEKARBONISASI INDUSTRI M
[2025-05-11, 11:35:06 UTC] [iqplus_etl_dag.py:735] INFO - 📄 Heringkas artikel 3/90: EKOM: BIO FARMA DORONG KEMANDIRIAN NASIONAL DALAM
[2025-05-11, 11:35:23 UTC] [iqplus_etl_dag.py:759] INFO - ✅ Transformasi selesai untuk artikel: EKOM: BIO FARMA DORONG KEMANDIRIAN NASIONAL DALAM
[2025-05-11, 11:35:23 UTC] [iqplus_etl_dag.py:735] INFO - 📄 Heringkas artikel 4/90: INEN: BANK ASING JUAL OBLIGASI INDIA AKIBAT KONFLI
[2025-05-11, 11:35:44 UTC] [iqplus_etl_dag.py:759] INFO - ✅ Transformasi selesai untuk artikel: INEN: BANK ASING JUAL OBLIGASI INDIA AKIBAT KONFLI
[2025-05-11, 11:35:44 UTC] [iqplus_etl_dag.py:735] INFO - 📄 Heringkas artikel 5/90: EKOM: IHSG SESI II DITUTUP MENGUAT 5 POIN KE LEVEL
[2025-05-11, 11:36:06 UTC] [iqplus_etl_dag.py:759] INFO - ✅ Transformasi selesai untuk artikel: EKOM: IHSG SESI II DITUTUP MENGUAT 5 POIN KE LEVEL
[2025-05-11, 11:36:06 UTC] [iqplus_etl_dag.py:735] INFO - 📄 Heringkas artikel 6/90: EKOM: BI PETAKAN DAN GALI INVESTASI POTENSIAL GENJ
[2025-05-11, 11:36:17 UTC] [iqplus_etl_dag.py:759] INFO - ✅ Transformasi selesai untuk artikel: EKOM: BI PETAKAN DAN GALI INVESTASI POTENSIAL GENJ
[2025-05-11, 11:36:17 UTC] [iqplus_etl_dag.py:735] INFO - 📄 Heringkas artikel 7/90: EKOM: PERTAMINA SUKSES CETAK 40 PEMIMPIN PEREMPUN
```

Transform IQplus melalui Airflow



Load IQplus melalui Airflow

4.3. IDX

A. Menambahkan dan Mengelola DAG

- Extract:

Proses ekstraksi pada IDX diimplementasikan dengan metode web scraping menggunakan Selenium. Berikut adalah langkah-langkah utama dalam proses ekstraksi, Pertama-tama, Program akan menyambungkan dengan MongoDB dimana setelahnya program akan mulai mencari dan mengunduh file instance.zip pada setiap emiten pada laman laporan keuangan IDX menggunakan Selenium. Sebelum diberikan ke MongoDB instance.zip akan di unzip dan isinya (Taxonomy.xsd dan instance.xrbl) akan diconvert menjadi JSON untuk selanjutnya disimpan di database idx_raw mongoDB dimana akan dibedakan berdasarkan tahun saja.

- Transform:

Untuk transformasi, kami menggunakan spark untuk memproses data secara paralel agar lebih cepat. Data pada idx_raw (hasil extract/scraping) akan diambil dan diseleksi berdasarkan kebutuhan (ada 32 atribut akhir yang kami ambil dari IDX ini) setelahnya langsung disimpan kembali di mongoDB pada database idx_transform.

- Load:

Komponen loading bertugas untuk memindahkan data yang telah diproses ke basis data yang akan diakses oleh aplikasi frontend. Proses ini mencakup pengambilan artikel yang telah diringkas dari tahap transformasi, lalu menyimpannya ke dalam database idx_final. Sistem akan mulai menyiapkan data yang diperlukan (32 atribut untuk informasi lengkap).

Untuk membuat data laporan keuangan ini dapat diakses, sebuah layanan API berbasis Flask diimplementasikan dengan berbagai fitur, seperti endpoint untuk mendapatkan data 32 atribut yang ada pada database itu.


5. API Untuk Dashboard

API untuk dashboard dibangun dari image khusus yang telah disiapkan sebelumnya. Walaupun sumber datanya sama, yaitu dari hasil transformasi data saham yang disimpan di database seperti MongoDB, bentuk dan cara pengelolaan API ini bisa berbeda tergantung kebutuhan visualisasi atau konsumsi data. Untuk mengatur bentuk dan alur API, dibuat folder khusus bernama **./api**, yang berisi skrip-skrip Flask atau framework lain. Di dalam folder ini, ditentukan bagaimana endpoint dibuat, data apa saja yang bisa diakses oleh frontend atau dashboard, serta bagaimana format respon yang dikirim ke pengguna. Dengan begitu, API


berfungsi sebagai jembatan antara data yang sudah siap dianalisis (serving layer) dan pengguna akhir yang membutuhkannya dalam bentuk visual atau laporan.

Dokumentasi Dashboard

1. Yfinance




Dashboard Tester API Yfinance



Dashboard Tester API Yfinance


2. IQplus



Dashboarad Tester API IQPlus

News Articles						
Title	Date	Summary	Original Words	Summary Words	Compression Ratio	Action
EKOM: BI PETAKAN DAN GALI INVESTASI POTENSIAL GENIOT EKONOMI DI BALI	Friday 09/ May/2025 at 16:13	Pemerintah Provinsi Bali menargetkan peningkatan pertumbuhan ekonomi yakni rentang 5,5 hingga 6,5 persen. Bank sentral itu mengadakan forum Bali Investment Challenge.	160	21	13.12	Detail
EKOM: PERTAMINA SUKSES CETAK 40 PEMIMPIN PEREMPUNAN	Friday 09/ May/2025 at 16:06	Komunitas PERTIWI telah menjadi motor penggerak dalam pembudayaan pekerja perempuan. PERTIWI berhasil mencetak 40 pemimpin perempuan di berbagai level di Pertamina Group. Kami yakin UMKM Indonesia bisa Go International.	370	29	7.84	Detail
EKOM: ANGGOTA DPR DUKUNG PENINGKATAN PRODUKSI MIGAS NASIONAL	Friday 09/ May/2025 at 16:05	Anggota Komisi XII DPR Eddy Soeparno mendukung upaya PT Pertamina Hulu Energi. Meningkatkan produksi minyak dan gas (migas) sehingga memperkuat peran terhadap ketahanan energi nasional.	128	25	19.53	Detail
EKOM: OJK MODAL ASING KELUAR PASAR SAHAM RI Rp90,72 TRILIUN HINGGA APRIL	Friday 09/ May/2025 at 15:52	Otoritas Jasa Keuangan (OJK) mencatat bahwa modal asing keluar bersih dari pasar saham Indonesia. April 2025 mencapai sebesar Rp90,72 triliun secara year-to-date.	190	22	11.58	Detail
EKOM: MIND ID BERSINERGI DENGAN PERGURUAN TINGGI GUNA DORONG HILIRISASI	Friday 09/ May/2025 at 15:49	MIND ID konsisten mengembangkan sektor industri pertambangan secara berkelanjutan. MIND ID mendorong perguruan tinggi untuk memperkuat program riset dan pengembangan.	130	20	15.38	Detail
INTEW: INVESTOR TETAP OPTIMIS, IMBAL HASIL OBLIGASI AS BERGERAK	Friday 09/ May/2025 at 15:46	Imbal hasil obligasi pemerintah AS sedikit berubah pada hari Jumat. Investor tetap optimis tentang kemungkinan AS mencapai kesepakatan perdagangan terkait tarif dengan mitra dagang internasional.	227	25	11.01	Detail
EKOM: INDONESIA BERENCANA KURANGI IMPOR BBM DARI SINGAPURA	Friday 09/ May/2025 at 15:35	Menteri Energi dan Sumber Daya Mineral (ESDM) Bahri Lahadalia mengungkapkan rencana untuk mengurangi impor bahan bakar minyak (BBM) dari Singapura. BBM yang kurang kompetitif apabila dibandingkan dengan BBM dari Timur Tengah. Pemerintah mulai membangun dermaga-dermaga yang mampu menampung kapal impor.	161	40	24.84	Detail
EKOM: JELANG LIBUR WAISAK, ASDP IMBALU PENGGUNA JASA BELI TIKET ONLINE	Friday 09/ May/2025 at 15:25	Menjelang libur panjang Hari Raya Waisak pada Senin, 12 Mei 2025, PT ASDP Indonesia Ferry (Persero) mengajak seluruh pengguna jasa penyeberangan untuk merencanakan perjalanan dengan cermat.	218	26	11.93	Detail
EKOM: MENTERI PU: SEKTOR INFRASTRUKTUR BERPERAN PENTING TURUNKAN NILAI IKOR	Friday 09/ May/2025 at 15:20	Menteri Pekerjaan Umum (PU) Dody Hanggodo mengungkapkan sektor infrastruktur berperan penting dalam menurunkan nilai Incremental Capital Output Ratio atau IKOR Indonesia.	172	21	12.21	Detail
EKOM: OJK: SEKTOR JASA KEUANGAN TERJAGA DI TENGAH TINGGINYA DINAMIKA EKONOMI	Friday 09/ May/2025 at 15:11	Otoritas Jasa Keuangan (OJK) melalui hasil Rapat Dewan Komisiner pada April 2025. OJK menilai bahwa stabilitas sektor jasa keuangan tetap terjaga di tengah-tengah.	148	23	15.54	Detail
INTEW: COMMERZBANK RAIH KENAIKAN LABA BERSIH 12%	Friday 09/ May/2025 at	Pendapatan tersebut menjadi persiapan untuk rapat pemegang saham tahunan mendatang. Commerzbank akan mencari dukungan investor	184	20	10.87	Detail

Dashboarad Tester API IQPlus



Dashboarad Tester API IQPlus

3. IDX

Financial Data Dashboard																	
Company Code	Year	Period	Company Name	Sector	Subsector	Revenue	Gross Profit	Operating Profit	Net Profit	Cash	Total Assets	Short Term Borrowing	Long Term Borrowing	Total Equity	Cash From Operations	Cash From Investing	Cash From Financing
ABDA	2021.00	audt	Awarder Siva Daria Awa Tbk	8. Finance	88. Insurance	Rp 0	Rp 103,871,837,000	Rp 138,190,287,000	Rp 662,081,096,000	Rp 2,477,781,048,000	0.00	0.00	1,397,280,002,000.00	Rp -222,057,086,000	Rp -115,251,667,000	Rp -27,048,401,800	1,901,545,646,000.00
ABBA	2021.00	audt	Melaka Media Tbk	9. Trade, Services & Investment	93. Advertising, Printing And Media	Rp 158,807,889,337	Rp 79,148,037,830	Rp -53,882,810,186	Rp -58,337,871,976	Rp 29,734,125,401	Rp 221,803,737,819	17,589,287,816.00	0.00	-1,903,708,138,158.00	Rp -50,488,130,370	Rp -412,232,115	Rp 54,723,341,888
AKU	2021.00	audt	Astra Agro Lestari Tbk	1. Agriculture	12. Plantation	Rp 18,807,044,000,000	2,952,891,800,000	1,584,343,000,000	Rp 893,779,000,000	Rp 979,892,000,000	27,781,231,000,000	0.00	5,823,933,000,000.00	19,247,794,000,000.00	Rp 2,332,194,000,000	Rp -998,180,000,000	8,513,437,600,000.00
ABM8	2021.00	audt	ABM Investama Tbk	9. Trade, Services & Investment	95. Investment Company	Rp 606,627,370	Rp 101,818,013	Rp -47,841,451	Rp 37,746,064	Rp 827,217,179	Rp 10,212,396	40,000,000.00	0.00	161,740,444.00	Rp -62,832,624	Rp -62,065,065	666,488,038.00
ACEE	2021.00	audt	Ace Hardware Indonesia Tbk	9. Trade, Services & Investment	93. Retail Trade	Rp 7,412,766,972,302	Rp 3,654,181,805,720	Rp 858,804,755,877	Rp 731,310,571,351	Rp 2,749,768,804,903	Rp 7,247,383,094,244	0.00	0.00	5,222,242,554,398.00	Rp 1,538,653,325,168	Rp -165,479,489,499	-626,037,974,393
ADCP	2021.00	audt	PT Adhi Comsumer Properti Tbk	8. Property, Real Estate And Building Construction	81. Property And Real Estate	Rp 977,221,009,504	Rp 175,538,098,188	Rp 125,880,134,350	Rp 133,251,182,454	Rp 44,998,678,735	Rp 4,878,308,827,347	0.00	311,822,544,333.00	1,989,034,919,870.00	Rp -231,413,933,812	Rp -150,739,802,544	Rp 124,174,740,131
ACST	2021.00	audt	PT Asasi Indonesia Tbk	8. Property, Real Estate And Building Construction	82. Building Construction	Rp 1,204,429,000,000	Rp 0	Rp -1,627,264,000,000	Rp -1,340,879,600,000	Rp 73,400,000,000	Rp 3,098,168,000,000	0.00	0.00	324,692,000,000.00	Rp 1,781,892,000,000	Rp -61,889,890,800	-1,884,014,309,300.00
ADHI	2021.00	audt	PT Adhi Karya (Persero) Tbk	8. Property, Real Estate And Building Construction	82. Building Construction	Rp 10,827,682,417,005	Rp 1,755,713,800,544	Rp -438,178,223,864	Rp -23,762,692,247	Rp 2,333,619,061,003	Rp 38,091,888,626,551	0.00	746,467,454,334.00	6,743,910,617,358.00	Rp 1,436,114,328,565	Rp -573,236,969,993	-1,754,218,138,185
ADIS	2021.00	audt	Alkerm Wira International Tbk Tbk	5. Consumer Goods Industry	51. Food And Beverages	Rp 873,104,000,000	Rp 342,565,000,000	Rp 187,881,000,000	Rp 131,769,000,000	Rp 338,488,000,000	Rp 916,791,000,000	0.00	0.00	700,388,000,000.00	Rp 230,879,000,000	Rp -1,838,000,000	-16,576,000,000
ADIP	2021.00	audt	Adira Diptanis Multi Resor Tbk	8. Finance	82. Financial Institution	Rp 0	Rp 0	Rp 1,479,245,000,000	Rp 1,235,573,000,000	Rp 78,172,000,000	Rp 29,203,013,000,000	0.00	0.00	7,825,279,000,000.00	Rp 8,462,733,000,000	Rp -132,091,000,000	21,325,238,000,000.00
ADMD	2021.00	audt	Polychem Indonesia Tbk	3. Basic Industry And Chemicals	34. Chemicals	Rp 152,752,710	Rp -17,915,587	Rp -38,508,191	Rp -38,676,045	Rp 11,041,822	Rp 205,764,198	0.00	0.00	167,481,988.00	Rp -1,654,302	Rp -608,291	Rp 0
ADNM	2021.00	audt	PT Adesa Mineral Indonesia Tbk	2. Mining	21. Coal Mining	Rp 333,333,937	Rp -11,170,874	Rp -58,739,709	Rp -38,152,837	Rp 43,572,296	Rp 855,202,280	0.00	0.00	258,148,499.00	Rp 29,791,089	Rp -52,419,819	396,076,013.00
ADRO	2021.00	audt	ADARO ENERGY Tbk	2. Mining	21. Coal Mining	Rp 2,534,642,000	Rp 978,729,089	Rp 132,740,000	Rp 153,901,000	Rp 1,173,703,000	Rp 6,381,988,000	0.00	42,903,000.00	3,851,714,000.00	Rp 738,793,000	Rp -351,897,000	2,428,852,000.00
AGAR	2021.00	audt	PT Agra Sagar Mitra Tbk	9. Trade, Services & Investment	91. Wholesale (Durable & Non-Durable Goods)	Rp 328,428,302,218	Rp 21,417,310,710	Rp -761,443,309	Rp -764,074,393	Rp 1,393,336,064	Rp 171,120,204,401	0.00	0.00	106,948,389,778.00	Rp 11,370,280,033	Rp -2,472,206,089	-11,693,048,170

Dashboarad Tester API IDX

6. Kesimpulan

Pipeline batch menggunakan Apache Airflow telah berhasil mengintegrasikan tiga sumber data berbeda—data historis saham dari YFinance, laporan keuangan dalam format XML dari situs resmi BEI, dan berita pasar modal dari situs [iqplus.info](https://www.iqplus.info) ke dalam satu alur ETL yang

terstruktur dan otomatis. Proses ini mencakup tahapan ekstraksi data, transformasi yang sesuai kebutuhan analisis, serta penyimpanan ke dalam database MongoDB

Data akhir yang dihasilkan dari pipeline ini telah tersedia dalam format yang optimal dan siap digunakan oleh berbagai sistem backend maupun frontend, khususnya untuk mendukung kebutuhan analitik dan visualisasi interaktif melalui dashboard.

Dengan memanfaatkan kemampuan orkestrasi Apache Airflow, sistem ini tidak hanya mendukung fleksibilitas dalam penambahan task baru dan penyesuaian logika bisnis, tetapi juga menawarkan skalabilitas seiring pertumbuhan volume data. Selain itu, Airflow menyediakan monitoring dan logging yang transparan, sehingga memudahkan tim data engineer dalam mendeteksi dan menangani potensi kegagalan proses.